

Detecção Automática de *Trialeurodes vaporariorum* em Cultivos de Tomate Utilizando Visão Computacional

Victor Augusto de Oliveira¹

¹Graduando em Engenharia de Computação, FHO - Fundação Hermínio Ometto, Araras, SP, 13607-339, Brasil

Correspondence

Victor Augusto de Oliveira, Curso de Engenharia de Computação, FHO - Fundação Hermínio Ometto, Av. Dr. Maximiliano Baruto, 500 - Jardim Universitário, Araras, SP, Brasil
Email: victoroliveira885@alunos.fho.edu.br

Funding information

Este trabalho foi financiado com recursos próprios.

A *Trialeurodes vaporariorum* (mosca-branca-de-estufa) é um vetor viral crítico na tomaticultura, exigindo monitoramento rigoroso para um controle eficaz. Visando superar as limitações de precisão da contagem manual em armadilhas cromotrópicas, este trabalho desenvolveu um modelo de detecção automática baseado na arquitetura YOLOv8s. A metodologia utilizou um subconjunto do dataset IP102 filtrado para classe única, aplicando uma estratégia de treinamento com otimizador AdamW e resolução de 512 pixels. Técnicas de aumento de dados agressivas, como o Mosaic, foram desativadas para preservar a detecção de pequenos objetos. Os resultados estabelecem uma base algorítmica robusta para a automação do monitoramento de pragas na região de Mogi Guaçu.

KEY WORDS

YOLOv8, *Trialeurodes vaporariorum*, Visão Computacional, IP102

1 | INTRODUÇÃO

A tomaticultura na região de Mogi Guaçu enfrenta desafios fitossanitários constantes, sendo a *Trialeurodes vaporariorum* (mosca-branca-de-estufa) uma das ameaças mais persistentes. Diferente de outras pragas, a *T. vaporariorum* atua como vetor eficiente para vírus que provocam o amarelamento e a clorose foliar, comprometendo a fotossíntese e a produtividade da lavoura.

A detecção precoce é fundamental para a decisão de controle. Tradicionalmente, utiliza-se armadilhas adesivas amarelas, cuja análise manual é dificultada pelo tamanho do inseto (1-2 mm) e pela fadiga visual dos técnicos. A Visão Computacional oferece uma alternativa escalável e objetiva. No entanto, a detecção de objetos pequenos em cenários de alta densidade permanece um desafio aberto na literatura de Deep Learning.

Este trabalho foca estritamente no desenvolvimento de software e na engenharia de machine learning. O objetivo é validar a eficácia da arquitetura YOLOv8s, uma evolução recente das redes de estágio único, configurada especificamente para reconhecer a morfologia da *T. vaporariorum*. O estudo detalha o processo de curadoria de dados, a seleção de hiperparâmetros para evitar overfitting e a avaliação métrica do modelo.

2 | TRABALHOS RELACIONADOS

O uso de Redes Neurais Convolucionais (CNNs) para identificação de pragas tem se consolidado como estado da arte. Khan et al. (2024) demonstraram que arquiteturas baseadas em YOLO superam métodos tradicionais de processamento de imagem em robustez e velocidade .

Especificamente para moscas-brancas, trabalhos anteriores focaram em modelos genéricos ou na detecção multiclasse. Kapetas et al. (2025) exploraram o uso de YOLO para insetos em estufas, apontando a importância da resolução da imagem na detecção de pequenos alvos . Este trabalho avança sobre essas premissas ao isolar a espécie *T. vaporariorum* do dataset público IP102 e aplicar uma estratégia de treinamento focada na estabilidade do gradiente (uso de AdamW) e na preservação de características finas, evitando augmentações destrutivas comuns em modelos genéricos.

3 | JUSTIFICATIVA

A região de Mogi Guaçu desempenha um papel relevante na produção de olerícolas no estado de São Paulo, com destaque para a cultura do tomate. No entanto, a sustentabilidade econômica desta atividade é frequentemente ameaçada pela incidência de vetores virais, sendo a *Trialeurodes vaporariorum* (mosca-branca-de-estufa) um dos agentes mais nocivos. A capacidade deste inseto de transmitir crinivírus, associada à sua rápida reprodução, exige um monitoramento populacional de alta frequência para fundamentar as decisões de manejo.

Atualmente, o monitoramento baseia-se na contagem visual em armadilhas cromotrópicas. Este método analógico apresenta gargalos críticos: é intensivo em mão de obra, propenso à fadiga visual e sujeito a alta variabilidade subjetiva entre diferentes técnicos. Em cenários de alta infestação, onde centenas de insetos milimétricos se sobrepõem na superfície adesiva, a precisão humana decai drasticamente, levando a estimativas errôneas que resultam ou em aplicações desnecessárias de defensivos (aumento de custo e impacto ambiental) ou em controle tardio (perda de produtividade).

A justificativa científica para este trabalho reside na necessidade de validar algoritmos de Visão Computacional capazes de superar essas limitações humanas. Enquanto a literatura já explora o uso de IA na agricultura, há uma

carência de estudos focados na otimização de hiperparâmetros específicos para a detecção de objetos minúsculos e densamente agrupados. O desenvolvimento de um modelo computacional robusto, treinado com rigorosa curadoria de dados, não apenas automatiza a contagem, mas padroniza o critério de avaliação, oferecendo uma base de dados confiável para a implementação futura de estratégias de Agricultura de Precisão.

4 | OBJETIVOS

4.1 | Objetivo Geral

Desenvolver e validar um modelo de Rede Neural Convolucional (CNN) baseado na arquitetura YOLOv8s, otimizado especificamente para a detecção e contagem automatizada da mosca-branca *Trialeurodes vaporariorum* em imagens de armadilhas adesivas.

4.2 | Objetivos Específicos

Para alcançar o objetivo geral, foram estabelecidas as seguintes metas técnicas:

- **Curadoria de Dados Orientada:** Construir um conjunto de dados especializado a partir do *dataset* IP102, aplicando filtragem taxonômica para isolar a classe alvo e desenvolvendo um *pipeline* de anotação híbrida (automática e manual) para garantir a qualidade do *Ground Truth*.
- **Engenharia de Modelo:** Configurar e treinar a rede neural YOLOv8s utilizando estratégias de otimização focadas em pequenos objetos, incluindo a seleção do otimizador AdamW, ajuste de resolução de entrada ($512px$) e personalização das técnicas de *Data Augmentation* (desativação de *Mosaic*).
- **Validação Algorítmica:** Avaliar o desempenho do modelo em um conjunto de teste isolado, utilizando métricas estatísticas de Precisão, Revocação e mAP (Média da Precisão Média), além de analisar a Matriz de Confusão para verificar a robustez contra falsos positivos.
- **Análise de Viabilidade:** Realizar *benchmarks* de velocidade de inferência (FPS) para determinar a aptidão do algoritmo para processamento em tempo real, independentemente da plataforma de hardware futura.

5 | METODOLOGIA

O desenvolvimento deste trabalho seguiu um fluxo estruturado em quatro etapas principais: (A) aquisição e curadoria de dados; (B) anotação assistida e refinamento manual; (C) configuração e treinamento da rede neural; e (D) validação e testes de performance. O processo focou na maximização da qualidade dos dados de entrada (*Data-Centric AI*) para compensar os desafios intrínsecos da detecção de pequenos insetos.

5.1 | Aquisição e Curadoria do Dataset

A base de dados primária utilizada foi o IP102, um *dataset* de referência para reconhecimento de pragas em larga escala. O processo de curadoria envolveu:

- **Filtragem Taxonômica:** Foram extraídas exclusivamente as imagens pertencentes à classe original 5 (*Trialeurodes*

vaporiorum).

- **Seleção Contextual:** Realizou-se uma triagem qualitativa para selecionar apenas as imagens que apresentavam contexto visual compatível com armadilhas cromotrópicas e folhas de tomateiro, descartando amostras com ruído excessivo ou fora do escopo da pesquisa.
- **Normalização de Classe:** Para fins de detecção binária, todos os metadados foram convertidos para uma estrutura de classe única (`class_id = 0`), designando a presença da mosca-branca.

5.2 | Anotação Híbrida (Semi-Supervisionada)

Para garantir a precisão do *Ground Truth*, foi desenvolvido um *pipeline* de anotação em duas fases, combinando automação algorítmica com supervisão humana.

1. Pré-anotação Automática: Foi desenvolvido um algoritmo de Visão Computacional Clássica (`auto_label.py`) para gerar caixas delimitadoras (*bounding boxes*) preliminares. Este algoritmo utiliza técnicas de pré-processamento de imagem, incluindo equalização de histograma (CLAHE) e filtragem de ruído (Non-local Means Denoising). A segmentação dos insetos foi realizada através de limiares de cor no espaço HSV, calibrados para identificar tanto adultos quanto ninfas, combinados com detecção de bordas (Canny) e filtragem por propriedades geométricas (área, circularidade e solidez).

2. Refinamento Manual: As anotações geradas automaticamente foram submetidas a uma ferramenta de revisão interativa desenvolvida especificamente para este projeto (`manual_label.py`). Esta etapa permitiu a correção de falsos positivos, o ajuste fino das coordenadas das caixas e a inclusão de insetos não detectados pelo algoritmo automático, assegurando um conjunto de dados de treinamento de alta fidelidade.

5.3 | Arquitetura e Estratégia de Treinamento

O modelo selecionado foi o **YOLOv8s (Small)**, escolhido por oferecer maior profundidade de camadas convolucionais em comparação à versão *Nano*, essencial para a extração de características sutis de objetos minúsculos. O treinamento foi executado utilizando a biblioteca *Ultralytics* sobre o framework PyTorch, com as seguintes configurações de hiperparâmetros otimizadas no script de treinamento (`model_trainer.py`):

- **Resolução de Entrada:** Imagens redimensionadas para 512×512 pixels, equilibrando a preservação de detalhes morfológicos com a eficiência de memória (VRAM).
- **Otimizador:** Utilizou-se o algoritmo **AdamW** com taxa de aprendizado inicial de 0.001 e momento de 0.937, visando uma convergência estável.
- **Regime de Épocas:** Configurado para 200 épocas com mecanismo de *Early Stopping* (paciente de 60 épocas) para evitar o superajuste (*overfitting*).
- **Aumento de Dados (Data Augmentation):** Técnicas agressivas de mistura de imagens, como *Mosaic* e *Mixup*, foram desativadas (`mosaic=0.0`). Esta decisão estratégica visa preservar a integridade visual dos pequenos objetos e evitar que a rede aprenda padrões de fundo artificiais. Foram mantidas apenas transformações geométricas leves (rotação, escala e translação).

5.4 | Validação e Métricas

A avaliação final do modelo foi conduzida por um script dedicado (`test_validation_model.py`), isolado do processo de treinamento para garantir isenção nos resultados. O modelo treinado foi submetido ao subconjunto de teste do dataset curado.

O desempenho foi mensurado utilizando as métricas padrão da competição COCO: Precisão (*Precision*), Revo-cação (*Recall*) e a Média da Precisão Média (mAP_{50} e mAP_{50-95}). Adicionalmente, foi gerada a Matriz de Confusão para analisar erros de classificação (falso-positivos vs. falso-negativos) e realizado um *benchmark* de velocidade de inferência para verificar a viabilidade computacional do algoritmo.

6 | RESULTADOS E DISCUSSÃO

O modelo YOLOv8s validou a eficácia da estratégia de treinamento (AdamW, 512px), demonstrando robustez na detecção da *Trialeurodes vaporariorum*.

6.1 | Desempenho Quantitativo e Viabilidade

A avaliação no conjunto de teste (Fig. 1) apresentou **Precisão de 89,61%**, minimizando falsos positivos críticos para o manejo, e **$mAP@0.5$ de 75,46%**. O **Recall de 67,93%** reflete a dificuldade inerente de oclusões em folhas densas.

Em termos de eficiência, o *benchmark* (Fig. 2a) registrou tempo médio de inferência de **13,98 ms** (\approx 71 FPS) em GPU, confirmando a aptidão para tempo real. A robustez é reforçada pela Matriz de Confusão (Fig. 2b), que indica ausência de confusão entre a classe *whitefly* e o fundo.

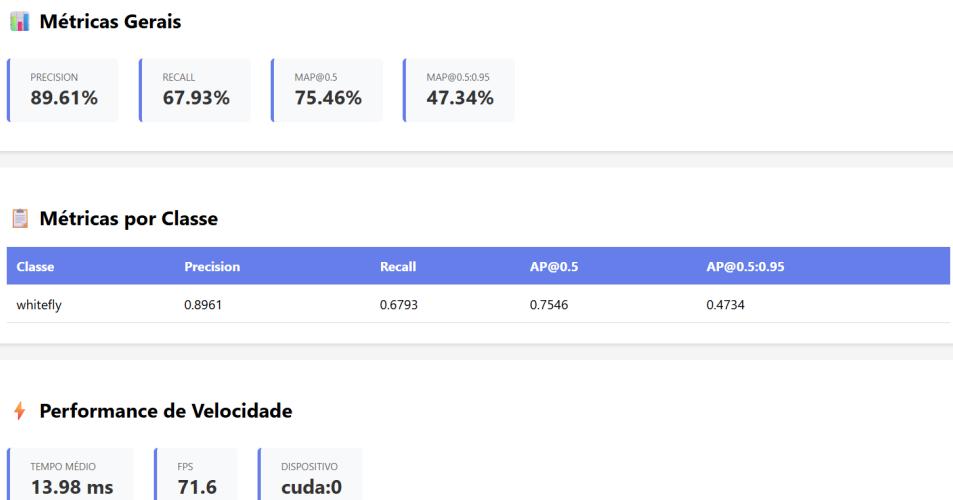
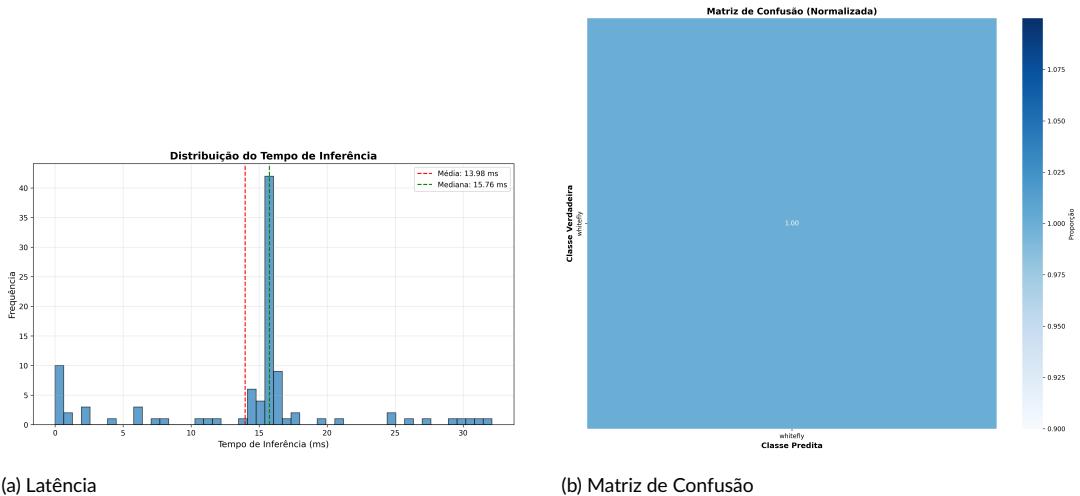


FIGURE 1 Métricas do conjunto de teste: alta precisão e velocidade compatível com tempo real.



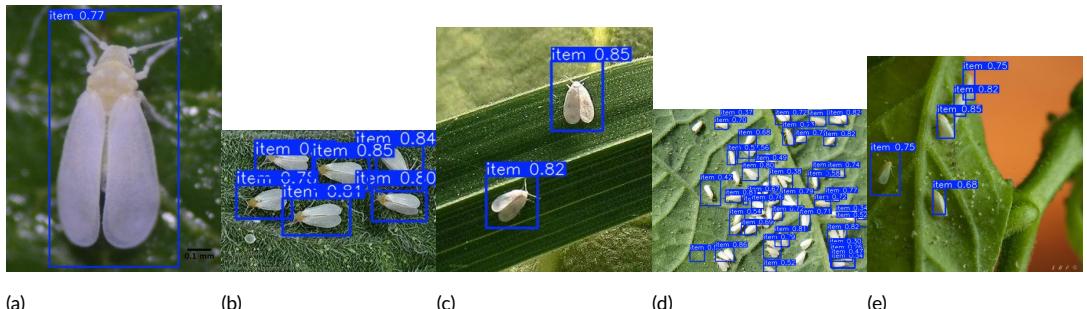
(a) Latência

(b) Matriz de Confusão

FIGURE 2 Métricas de eficiência (a) e classificação (b).

6.2 | Análise Qualitativa

A Figura 3 ilustra a generalização do modelo. Em (a) e (b), observa-se a identificação precisa de detalhes morfológicos e pequenos grupos; em (c), a detecção em folhas texturizadas; e em (d) e (e), a robustez em cenários críticos de alta densidade e oclusão lateral, validando a decisão de desativar o Mosaic para preservar a integridade dos objetos.

**FIGURE 3** Resultados qualitativos: (a) Close-up; (b) Pequenos grupos; (c) Contexto de folha; (d) Alta densidade; (e) Oclusão.

7 | CONCLUSÃO

Este trabalho atingiu o objetivo de desenvolver e validar uma solução algorítmica robusta para a detecção automática da *Trialeurodes vaporariorum*, superando os desafios impostos pela morfologia diminuta do inseto e pela complexidade visual das armadilhas em campo.

Os resultados quantitativos validam a escolha da arquitetura YOLOv8s combinada com uma estratégia de treina-

mento conservadora. A Precisão de 89,61% é o indicador mais relevante para a aplicação prática no Manejo Integrado de Pragas (MIP), pois assegura que o sistema raramente gera falsos positivos, garantindo credibilidade às estimativas populacionais. Embora o Recall de 67,93% reflete a dificuldade intrínseca de detectar espécimes severamente oclusos ou degradados, a alta taxa de quadros por segundo (71,6 FPS) confirma a viabilidade do modelo para processamento em tempo real e escalabilidade.

A metodologia de *Data-Centric AI*, priorizando a curadoria híbrida do *dataset* e a remoção de técnicas de aumento de dados agressivas (como o *Mosaic*), provou-se decisiva para preservar a integridade das características visuais da praga.

Para a tomaticultura de Mogi Guaçu, esta pesquisa entrega um artefato tecnológico capaz de substituir a subjetividade da contagem manual por métricas padronizadas e auditáveis. Como trabalhos futuros, sugere-se a expansão do *dataset* para incluir outras espécies de aleirodídeos (como *Bemisia tabaci*) visando a classificação taxonômica fina, e a investigação de técnicas de rastreamento temporal (*tracking*) para melhorar a contagem em vídeos contínuos.

references

- [1] A. Khan, S. J. Malebary, L. M. Dang, F. Binzagri, H.-K. Song, and H. Moon, "AI-Enabled Crop Management Framework for Pest Detection Using Visual Sensor Data," *Plants*, vol. 13, no. 5, p. 653, 2024.
- [2] D. Kapetas, P. Christakakis, S. Faliagka, N. Katsoulas, and E. M. Pechlivanis, "AI-Driven Insect Detection, Real-Time Monitoring, and Population Forecasting in Greenhouses," *AgriEngineering*, vol. 7, no. 2, p. 29, 2025.
- [3] B. Kariyanna and M. Sowjanya, "Unravelling the use of artificial intelligence in management of insect pests," *Smart Agricultural Technology*, vol. 8, p. 100517, 2024.
- [4] G. Jocher, A. Chaurasia, and J. Qiu, "Ultralytics YOLO," version 8.0.0, 2023. [Online]. Available: <https://docs.ultralytics.com/>
- [5] A. Paszke et al., "PyTorch: An Imperative Style, High-Performance Deep Learning Library," in *Advances in Neural Information Processing Systems* 32, 2019, pp. 8024–8035. [Online]. Available: <https://pytorch.org/docs/stable/index.html>
- [6] G. Bradski, "The OpenCV Library," *Dr. Dobb's Journal of Software Tools*, 2000. [Online]. Available: <https://docs.opencv.org/4.x/>
- [7] The pandas development team, "pandas-dev/pandas: Pandas," Zenodo, 2020. [Online]. Available: <https://pandas.pydata.org/docs/>